

Nom complet : Amara DOUMBOUYA

Master 1

Cours : Data mining

Traité du TP S2

Identification des 7 étapes KDD sur un mini-dataset : dataset_ventes_fictives.csv

Etape KDD	Action concrète	Problème potentiel	Outil python
1. Data integration	Regrouper les données provenant de plusieurs fichiers CSV ou feuilles Excel dans un seul dataset exploitable. Vérifier que les colonnes ont les mêmes noms et formats.	Données dupliquées ou formats incompatibles.	pandas
2. Data selection	Sélectionner uniquement les colonnes utiles comme : produit, quantité, prix, date et ville. Ignorer les informations inutiles pour l'analyse.	Sélection de mauvaises variables ou perte d'informations importantes.	pandas
3. Data cleaning	Corriger les valeurs manquantes, supprimer les doublons et uniformiser les	Valeurs nulles, données incohérentes ou bruitées.	pandas, numpy

	données. Vérifier aussi les erreurs de saisie.		
4. Data transformation	Convertir certaines colonnes dans un format adapté, par exemple transformer la date en mois/année ou normaliser les montants.	Mauvaise transformation pouvant fausser l'analyse.	pandas, sklearn.preprocessing
5. Data mining	Appliquer une méthode d'analyse comme la classification, le clustering ou les statistiques pour découvrir des tendances de ventes.	Mauvais choix d'algorithme ou résultats peu pertinents.	scikit-learn
6. Pattern evaluation	Évaluer les résultats obtenus afin de vérifier si les tendances découvertes sont utiles et fiables. Comparer les performances du modèle.	Résultats peu précis ou interprétation incorrecte.	sklearn.metrics
7. Knowledge presentation	Présenter les résultats sous forme de graphiques, tableaux ou rapports afin de faciliter la compréhension des décisions.	Visualisations difficiles à comprendre.	matplotlib, seaborn